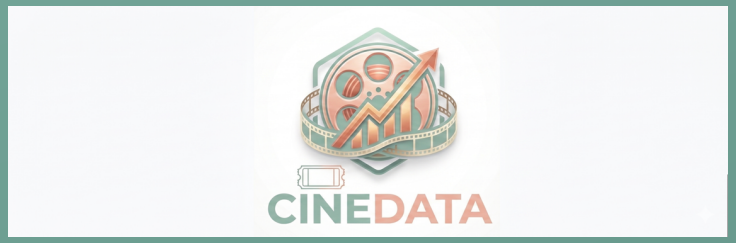
01

Introduction & Problématique

PROJET · GROUPE TD2 · 2026



CineData

Bases de données & Sciences des données 2

Analyse croisee de l'industrie cinematographique mondiale et de la distribution en France **(2000–2024)**

> *Existe-t-il une relation entre les caracteristiques d'un film — budget, realisateur, pays d'origine, critiques — et son succes commercial mondial ainsi que son autorisation d'exploitation en France ?*

Sources · Kaggle — Movies Box Office (2000–2024) · Data.gouv.fr — Visas CNC (1945–2025)

Realise avec R Markdown & Xaringan

30 April 2026

BERRANDOU Fatima
HO Emmy
JEBBAR Safae
LEONE Esther

Departement MIASHS
Universite Paul-Valery Montpellier

Sommaire

01 Introduction & Problematique

02 Modelisation Conceptuelle (MCD)

03 Analyse statistique — Graphiques

04 Analyse statistique — Tests & Interpretations

05 Difficultes

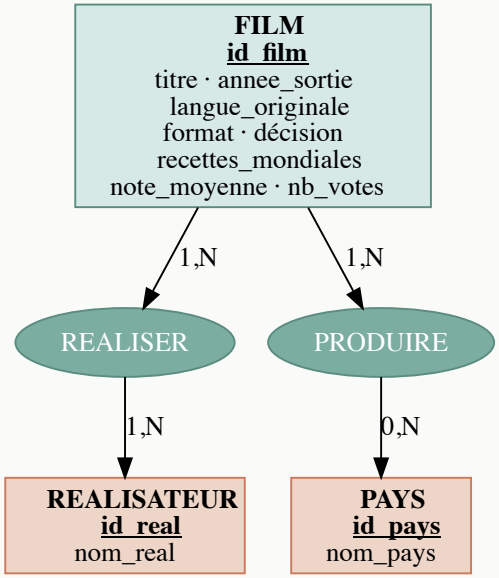
06 Conclusion & Perspectives

02

Modelisation

MCD · Modele Relationnel · phpMyAdmin

Modele Conceptuel (MCD)



FILM — entite centrale

Point de fusion Kaggle / CNC

REALISATEUR — table de reference

Relation 1:N avec FILM

Evite la redondance des noms

PAYS — table de reference

Relation 1:N avec FILM

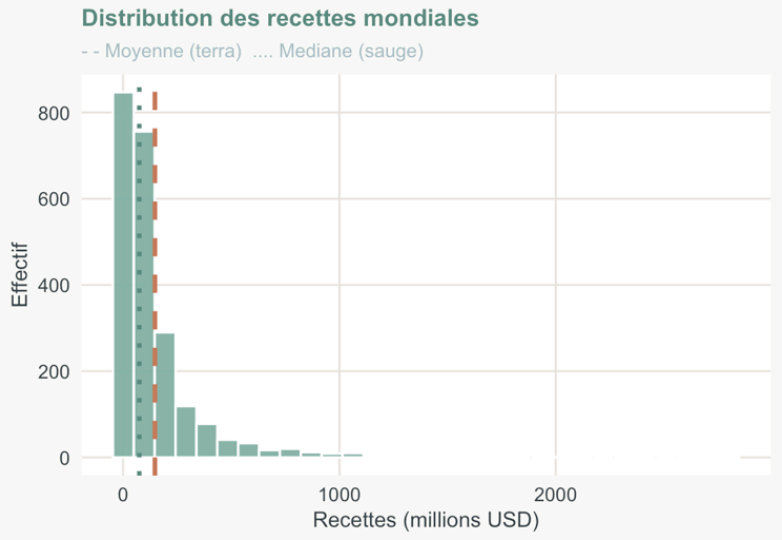
Traitement des coproductions

03

Analyse Exploratoire des Données

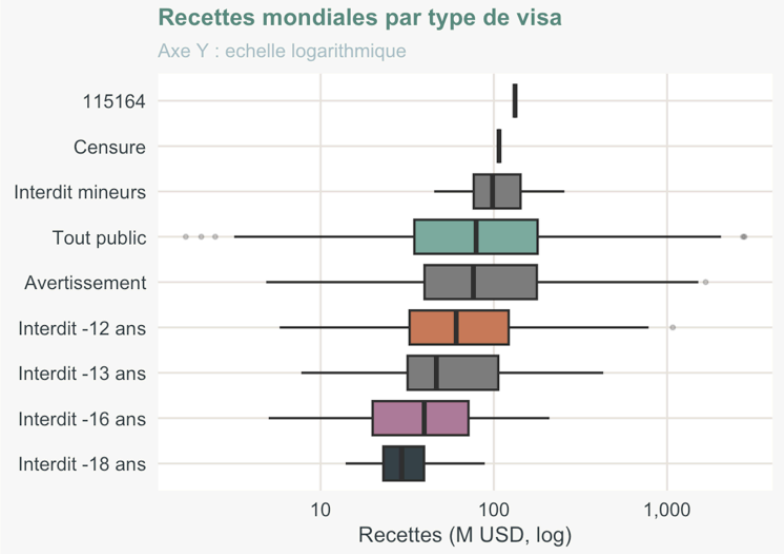
Variables univariees & bivariees

EDA — Variables quantitatives



***Recettes** : distribution asymetrique a droite — moyenne (147 M$) > mediane (75 M$) — quelques blockbusters concentrent les valeurs extremes*
***Notes** : concentrees entre 6 et 8/10 — moyenne 6,56 — biais de selection probable*

EDA — Variables qualitatives & bivariees



***Visa** : "Tout public" = 73 % de la base (1 643 films sur 2 249)*
***Format** : longs-metrages = 81 % (1 828 films) — justifie de concentrer l'analyse sur ce format*

EDA — Synthese et points cles

Observation des données

Recettes mondiales

Distribution asymetrique a droite — moyenne 147 M$ > mediane 75 M$
→ Quelques blockbusters concentrent les valeurs extremes

Notes moyennes

Moyenne = 6,56
→ Peu de films très mal notés

Observations qualitatives

Repartition des visas

"Tout public" = 73 % de la base (1 643 films)
Categories restrictives minoritaires mais pertinentes

Format predominant

Longs-metrages = 81 % des films (1 828 films)

*Ces observations motivent les deux tests suivants : **ANOVA** pour comparer les recettes selon le visa.*

04

Tests Statistiques & Interpretations

ANOVA · Regression lineaire · Resultats

ANOVA — Recettes mondiales par visa

Justification

Variable quantitative (`recettes_mondiales`)
x Variable qualitative (`décision` , k >= 2 groupes)
→ **ANOVA a un facteur**

H0 : mu(Tout public) = mu(-12) = mu(-16) = mu(-18)
H1 : au moins une moyenne differe
alpha = 5 %

Presupposes verifies

- **Normalite** : test d'Homogéneité par groupe
  ANOVA robuste si n suffisant
- **Homoscedasticite** : test de Bartlett
  Si rejete → ANOVA (`var.equal = FALSE`)

Test d'Homogeneite

p < 0,001 — egalite des variances rejetee
→ ANOVA de Welch appliquee (`var.equal = FALSE`)

Tableau ANOVA

Terme	dl	F	p-valeur
décision	8	3,549	< 0,001
Residuals	2 240	—	—

η^2 = 0,0125
Effet faible (seuil : 0,01 = faible · 0,06 = modere · 0,14 = large)
→ Le visa explique une part limitee des recettes

Regression lineaire — Recettes ~ Note

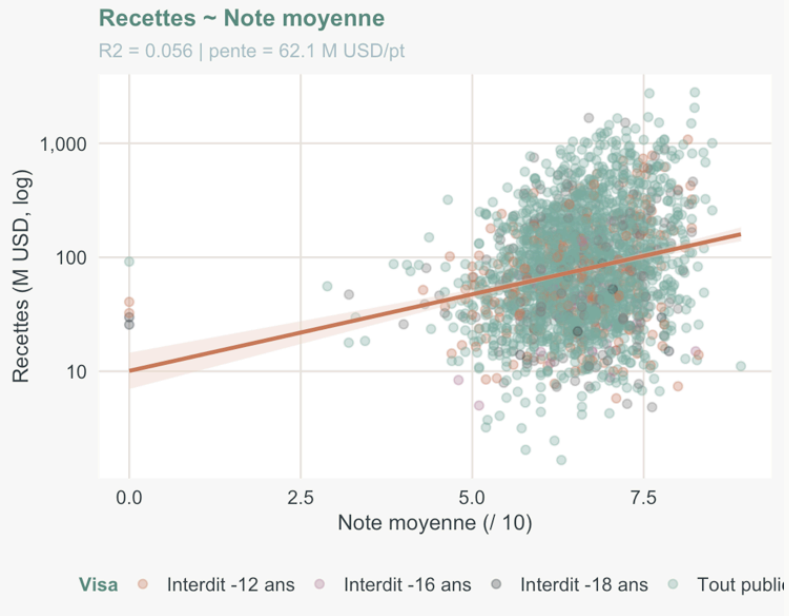
Modèle

$$Y_i = \beta_0 + \beta_1 \times \text{note}_i + \varepsilon_i$$

avec $\varepsilon_i \sim \mathcal{N}(0, \sigma^2)$ i.i.d.

```
beta0 = -260.2 M USD
beta1 = 62.1 M USD/pt
R2    = 0.0557
p(b1) = 0
```

R^2 = 0,056
Pente = + 62,1 M$ par point de note R^2 faible : note = un facteur parmi d'autres
Budget · franchise · marketing jouent aussi un role



Resultats — Synthese des analyses

ANOVA — Recettes mondiales par type de visa

Resultat : η^2 = 0,0125 → effet faible Les recettes moyennes **different** significativement selon la catégorie de visa

Regression lineaire — Note → Recettes mondiales

Resultat : R^2 = 0,056 → pouvoir explicatif faible
Influence positive confirmee — succes commercial reste **multidimensionnel**

Aucune variable seule n'explique pleinement la performance commerciale

05

Difficultées & Discussion

Problème rencontré par le groupe

Discussion & Limites

Difficultes rencontrées



Limites identifiees

- Données Kaggle synthetiques — surrepresentation anglophone
- Appariement approximatif titre + annee → erreurs potentielles (~5–10%)

06

Conclusion

Bilan · Apports · Perspectives

Conclusion

Traitement des données

Collecte CSV → nettoyage R → base SQL normalisee
5 tables · cles etrangeres · 2 249 films aparies

Modelisation

MCD → MOD → phpMyAdmin
Contraintes d'integrite referentielle
Tables de jonction N:M

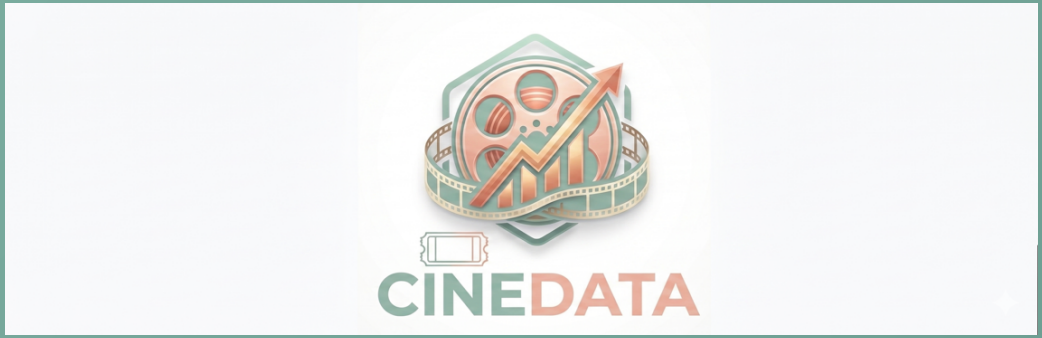
Analyses statistiques

EDA univariee & bivariee
ANOVA · Regression lineaire
Calcul η^2 et V de Cramer

Resultats cles

Succès = facteur multidimensionnel
Visa "Tout public" → avantage commercial
Note → correle positivement aux recettes (effet modere)

Questions



Existe-t-il une relation entre les caracteristiques d'un film — budget, realisateur, pays d'origine, critiques — et son succes commercial mondial ainsi que son autorisation d'exploitation en France ?

Sources de données

Kaggle — Box Office Dataset (2000–2024)

`kaggle.com/datasets/aditya126/movies-box-office-dataset`

CNC — Visas d'exploitation (1945–2025)

`data.gouv.fr/datasets/liste-des-visas-dexploitation`

Outils utilises

`R 4.3.x · RStudio · phpMyAdmin · MAMP`

`ggplot2 · dplyr · DiagrammeR · DBI · RMySQL`