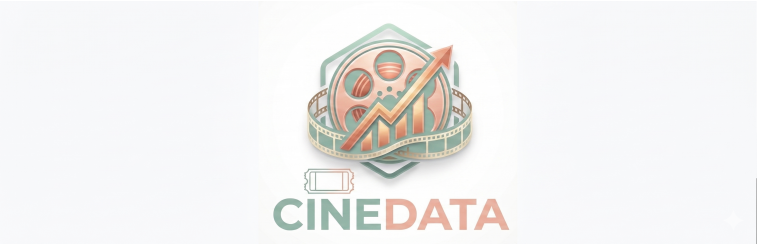
PROJET RÉALISÉ PAR

L'ÉQUIPE CINÉ DATA DU GROUPE DE TD2



RAPPORT DE GROUPE DES UE \BASES DE DONNÉES \SCIENCES DES DONNÉES 2

BERRANDOU FATIMA, HO EMMY, JEBBAR SAFAE & LEONE ESTHER

Mis à jour le 18 October 2026

Département MIASHS, UFR 6 Informatique, Mathématique et Statistique
Université de Montpellier Paul-Valéry

18 Octobre 2026

Soumis comme contribution partielle
pour le cours Science des données 2 et Bases de données

Déclaration de non plagiat

Nous déclarons que ce rapport est le fruit de notre seul travail, à part lorsque cela est indiqué explicitement.

Nous acceptons que la personne évaluant ce rapport puisse, pour les besoins de cette évaluation :

- la reproduire et en fournir une copie à un autre membre de l'université ; et/ou,
- en communiquer une copie à un service en ligne de détection de plagiat (qui pourra en retenir une copie pour les besoins d'évaluation future).

Nous certifions que nous avons lu et compris les règles ci-dessus.

En signant cette déclaration, nous acceptons ce qui précède.

Signature : Fatima BERRANDOU Date : 18 October 2026

Signature : Emmy HO Date : 18 October 2026

Signature : Safae JEBBAR Date : 18 October 2026

Signature : Esther LEONE Date : 18 October 2026

18 octobre 2026

Remerciements

Nous remercions Madame Sandra Bringay et Madame Marine Demangeot pour leur encadrement, leur disponibilité et la qualité de leurs conseils, qui ont largement contribué à l'avancement et à la réussite de ce projet.

Nous adressons également nos remerciements à l'ensemble de l'équipe du groupe pour son engagement et sa collaboration. Chaque membre a contribué par ses idées et son implication, en faisant preuve de sérieux et de rigueur dans la réalisation de nos objectifs communs.

18 octobre 2026

Résumé

Ce rapport présente une analyse croisée de l'industrie cinématographique, alliant performance économique mondiale et régulation administrative française. À travers la fusion d'un jeu de données synthétique (Kaggle) et des registres officiels du CNC (visas d'exploitation), l'étude examine comment des facteurs tels que la classification d'âge, l'origine géographique et la réception critique influencent le succès financier d'une œuvre.Après une phase de nettoyage et de modélisation SQL sur plus de 2 000 films, nos analyses révèlent que si une audience large (visa "Tout public") favorise mécaniquement les recettes, le succès reste une variable complexe. La corrélation entre les notes des spectateurs et le box-office, bien que réelle, montre que la qualité perçue n'est qu'un moteur parmi d'autres, laissant une place prépondérante aux stratégies de marketing et à la notoriété des studios.

Table des matières

Chapitre 1 Introduction 1
- 1.1 Introduction . . . 1
- 1.2 Responsabilités et composition de l'équipe . . . 1

Chapitre 2 Base de données provenance et caractérisation 2
- 2.1 Description des sources . . . 2
  - 2.1.1 Synthetic Movie Dataset (Kaggle) . . . 2
  - 2.1.2 Liste des visas d'exploitation cinématographique (Data.gouv.fr) 2
- 2.2 Sélection et Nettoyage (*Data Cleaning*) . . . 2
- 2.3 Choix de la structure de stockage . . . 2

Chapitre 3 Traitement des données 3
- 3.1 Présentation générale . . . 3
- 3.2 Sources utilisées . . . 3
- 3.3 Étapes de traitement . . . 3

Chapitre 4 Description des tables 4
- 4.1 Tables . . . 4
- 4.2 Schéma relationnel . . . 5

Chapitre 5 Modélisation Conceptuelle (MCD) et Stratégie de Corrélation 6
- 5.1 Mécanisme de corrélation entre les jeux de données . . . 6
- 5.2 Objectifs de l'analyse via ce modèle . . . 7

Chapitre 6 Modèle Relationnel (MOD) et Implémentation Technique 8
- 6.1 Processus d'implémentation : de RStudio vers SQL . . . 8
- 6.2 Potentiel analytique de la base SQL . . . 9
- 6.3 Aperçu de l'implémentation dans phpMyAdmin . . . 9

Chapitre 7 Analyses et Requêtes SQL 10
  - 7.0.1 Protocole de connexion . . . 10
- 7.1 Requêtes réalisées . . . 10
  - 7.1.1 Statistiques sur la production française . . . 11
  - 7.1.2 Analyse des restrictions (Visas CNC) . . . 12
  - 7.1.3 Analyse du Box-Office Mondial (2000–2024) . . . 13
  - 7.1.4 Croisements et Comparaisons (Jointures) . . . 15
  - 7.1.5 Requête synthétique . . . 18
- 7.2 Analyse de la rentabilité par type de visa . . . 19

Chapitre 8 Matériel et Méthodes 21
8.1 Logiciels . . . 21
8.2 Chargement des données . . . 21
8.3 Modélisation statistique . . . 21

Chapitre 9 Analyse Exploratoire des Données 22
9.1 Résumés numériques univariés . . . 22
9.1.1 Variables quantitatives . . . 22
9.1.2 Variables qualitatives . . . 22
9.2 Résumés graphiques univariés . . . 23
9.2.1 Distribution des recettes mondiales . . . 23
9.2.2 Répartition par type de visa (diagramme en barres) . . . 24
9.3 Résumés graphiques bivariés . . . 24
9.3.1 Boxplots : recettes mondiales par type de visa . . . 24
9.4 ANOVA : comparaison des recettes moyennes par type de visa . . . 25
9.4.1 Vérification des présupposés . . . 25
9.4.2 Application de l'ANOVA . . . 25
9.4.3 Calcul du rapport de corrélation η^2 . . . 25
9.5 Régression linéaire simple : recettes mondiales ~ note moyenne . . . 26
9.5.1 Justification . . . 26
9.5.2 Ajustement du modèle . . . 26
9.5.3 Vérification des résidus . . . 27
9.5.4 Droite de régression ajustée . . . 28

Chapitre 10 Interprétation des Tests 29

Chapitre 11 Discussion 30

Chapitre 12 Conclusion et perspectives 31

Récapitulatifs des figures 32

Chapitre 1

Introduction

1.1 Introduction

L'industrie cinématographique est un secteur complexe où se croisent des enjeux artistiques, culturels et financiers. Chaque année, des milliers de films sont produits à travers le monde, mais seuls quelques-uns parviennent à dominer le Box-Office mondial ou à franchir les frontières pour s'exporter durablement. Comprendre les facteurs qui déterminent le succès d'un film constitue donc un enjeu majeur pour les acteurs du secteur.

Le présent rapport s'appuie sur l'analyse croisée de deux sources de données complémentaires. La première, issue de Kaggle, fournit une vision globale et quantitative de l'industrie : elle regroupe des informations détaillées sur le budget de production, les performances commerciales et la réception critique du public. La seconde source, provenant de data.gouv.fr, recense les visas d'exploitation délivrés par le Centre National du Cinéma (CNC) depuis 1945, offrant un éclairage spécifique sur le marché français. Le croisement entre ces données permet d'étudier le lien entre succès commercial et accès au marché français.

L'objectif de cette étude est d'identifier les facteurs influençant la performance d'un film et son obtention d'un visa d'exploitation en France, afin de mieux comprendre les mécanismes de réussite et de diffusion dans un contexte international et réglementé.

Existe-t-il une relation entre les caractéristiques d'un film (budget, réalisateur, pays d'origine, critiques) et son succès commercial mondial ainsi que son autorisation d'exploitation en France ?

1.2 Responsabilités et composition de l'équipe

BERRANDOU Fatima : Étudiante n°22401845
Resp. MOD, Coresp. Requête SQL, Coresp. Rapport
HO Emmy : Étudiante n°22209880
Resp. MCD, Coresp. Requête SQL, Coresp. Rapport
JEBBAR Safae : Étudiante n°22304332
Resp. Collecte de données, Coresp. Requête SQL, Coresp. Rapport, Resp. Rapport rmd
LEONE Esther : Étudiante n°22313119. Resp Nettoyage de données, Coresp. Rapport, Coresp. Requête SQL

Chapitre 2

Base de données provenance et caractérisation

La qualité d'une analyse de données repose avant tout sur la fiabilité et la pertinence des sources sélectionnées. Pour ce projet, nous avons croisé un jeu de données international avec un registre administratif français.

2.1 Description des sources

2.1.1 Synthetic Movie Dataset (Kaggle)

Le jeu de données a été récupéré sur la plateforme Kaggle. Il s'agit d'un fichier au format `.csv`(17 colonnes pour $>$ 500 000 lignes). Il contient des données technico-économiques (budget, box-office) et sociales.

2.1.2 Liste des visas d'exploitation cinématographique (Data.gouv.fr)

Le jeu de données a été récupéré sur le portail officiel des données publiques françaises. Il s'agit d'un fichier `.csv`(8 colonnes), recensant les films depuis 1945 et contenant notamment des numéro de visa, décision de classification et date de délivrance.

2.2 Sélection et Nettoyage (*Data Cleaning*)

Afin de garantir la cohérence de notre base de données, nous avons effectué des choix de filtrage stricts :

Le dataset Kaggle a été réduit de 17 à 8 colonnes, en éliminant les données textuelles et visuelles pour se concentrer exclusivement sur le **Budget**, les **Recettes**, les **Notes** et le **Réalisateur**. Parallèlement, le dataset Visas a été traité en privilégiant le **Numéro de visa** comme clé primaire et la **Décision administrative**. L'analyse a été restreinte aux films sortis entre **2000 et 2024** afin de permettre une comparaison pertinente des budgets face à l'inflation et d'assurer la représentativité des critiques numériques. Enfin on a exclus les lignes présentant un budget de "0" ou des recettes manquantes, pour garantir l'intégrité des calculs de rentabilité.

2.3 Choix de la structure de stockage

Bien que les données sources soient en `.csv`, nous avons choisi de les importer dans un **SGBD Relationnel (SQL via phpMyAdmin)** pour forcer les liens entre un film et son visa (Clé Étrangère) évite les erreurs de saisie. Ainsi qu'une création de tables dédiées (**REALISATEUR** et **PAYS**) pour éviter la redondance (Normalisation). Au lieu de répéter un nom 50 fois, nous utilisons un identifiant unique. Et enfin le SQL permet des jointures complexes pour comparer instantanément les revenus mondiaux avec les régulations françaises.

Finalement, définir clairement quelle est la **population étudiée**.

Chapitre 3

Traitement des données

3.1 Présentation générale

Cette base de données cinématographique a été constituée à partir de la fusion des deux sources distinctes présentées précédemment.

L'appariement entre les deux sources a été réalisé via le **titre en anglais** des films (`Titre_EN` côté CNC, `Title_EN_corrected` côté box-office). Seuls les films présents dans les deux bases ont été conservés (jointure interne). Les doublons ont été traités en privilégiant la ligne la plus complète.

La base finale est organisée en **deux fichiers CSV** normalisés, décrits ci-dessous.

3.2 Sources utilisées

Source	Période	Lignes	Description
Visas CNC	1945–2025	~95 700	Données réglementaires et administratives françaises
Box-office international	2000–2024	5 000	Recettes, notes et métadonnées de films anglophones

3.3 Étapes de traitement

1. Chargement et normalisation Les titres anglais des deux sources ont été normalisés (suppression des espaces, mise en minuscules) pour permettre la correspondance.

2. Déduplication Les deux sources contenaient des doublons sur les titres. En cas de titre en double, la ligne conservée est celle présentant le plus grand nombre de champs renseignés (côté CNC) ou le plus grand nombre de votes (côté box-office).

Les deux étapes précédentes ont pu être réalisé à l'aide de l'ia nous permettant d'accélérer cette phase et se concentre sur l'étape suivante.

3. Nettoyage La colonne `Format` du fichier CNC présentait des valeurs aberrantes (longues chaînes de noms de sociétés de production dues à des erreurs de saisie). Ces valeurs ont été remplacées par des valeurs manquantes. Les entrées "Non renseigné" et les artefacts numériques ont été exclus des tables de référence.

4. Fusion et construction des tables Les trois tables (`FILM`, `RÉALISATEUR`, `PAYS`) ont été construites depuis le jeu de données fusionné (2 249 films appariés).

Chapitre 4

Description des tables

4.1 Tables

Table 1 : Film (2 249 x 12)

Colonne	Type	Description	Caractéristique
id_film	integer	Identifiant unique du film	clé primaire de la table film
titre	character	Titre du film en anglais	unique et pas de valeurs manquantes
année_sortie	numeric	Année de sortie (source : CNC)	pas de valeurs manquantes
langue_originale	character	Code ISO 639-1 de la langue originale	en, fr, es
format	character	Format du film	Long métrage, Court-métrage, Moyen-métrage
décision	character	Décision de visa CNC	Tout public, Interdit -12ans,-16ans,-18ans, Avertissement
localisation_dossier	character	Lieu d'archivage du dossier	CNC, Archives nationales
recettes_mondiales	numeric	Recettes mondiales totales en USD	pas de valeurs manquantes
recettes_domestiques	numeric	Recettes sur le marché nord-américain en USD	pas de valeurs manquantes
recettes_étrangères	numeric	Recettes sur les marchés internationaux en USD	pas de valeurs manquantes
note_moyenne	numeric	Note moyenne sur 10 (source : box-office)	Compris entre 1 et 10
nb_notes	numeric	Nombre de votes ayant contribué à la note	pas de valeurs manquantes

Relation avec les autres tabes
— `id_réal` → clé étrangère vers `RÉALISATEUR.id_réal`.
— `id_pays` → clé étrangère vers `PAYS.id_pays`.

Table 2 : Réalisateur (1 449 x 2)

Colonne	Type	Description	Caractéristique
`id_réal`	`integer`	Identifiant unique du réalisateur	clé primaire de la table réalisateur
`réalisateur`	`character`	Nom complet du réalisateur	format variable selon saisie source

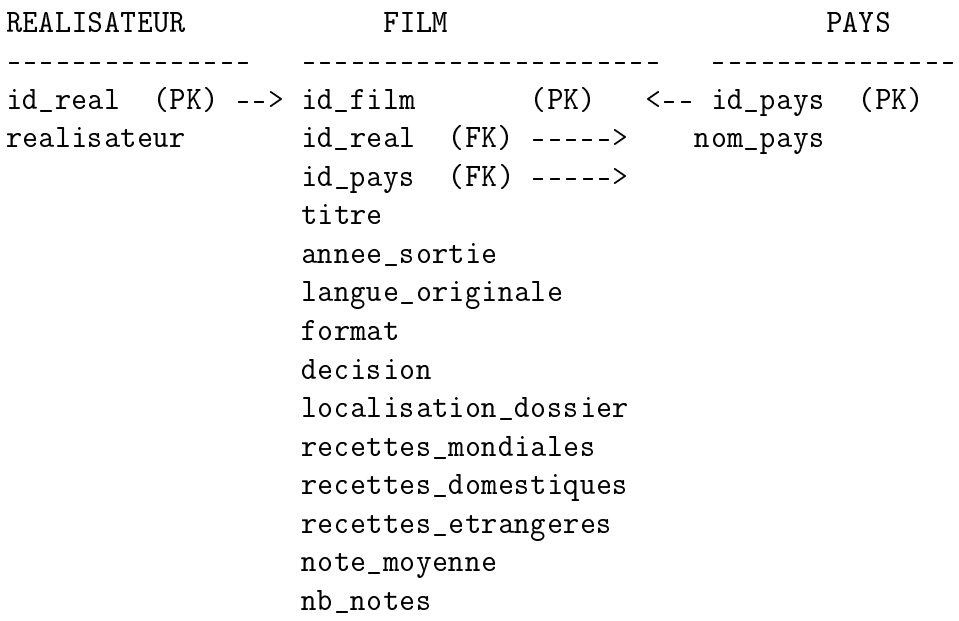
Relation avec les autres tabes
— Lié à `FILM` via une clé étrangère `id_réal` (relation **1 :N** — un réalisateur peut avoir réalisé plusieurs films).

Table 3 : Pays (131 x 2)

Colonne	Type	Description	Caractéristique
`id_pays`	`integer`	Identifiant unique de l'entrée pays	clé primaire de la table pays
`nom_pays`	`character`	Nom du pays ou nationalités	

Relation avec les autres tabes - Lié à `FILM` via une clé étrangère `id_pays` (relation **1 :N** — une nationalité peut être partagée par plusieurs films).

4.2 Schéma relationnel



Les clés étrangères `id_réal` et `id_pays` sont à implémenter dans `FILM` lors de l'intégration en base de données.

Chapitre 5

Modélisation Conceptuelle (MCD) et Stratégie de Corrélation

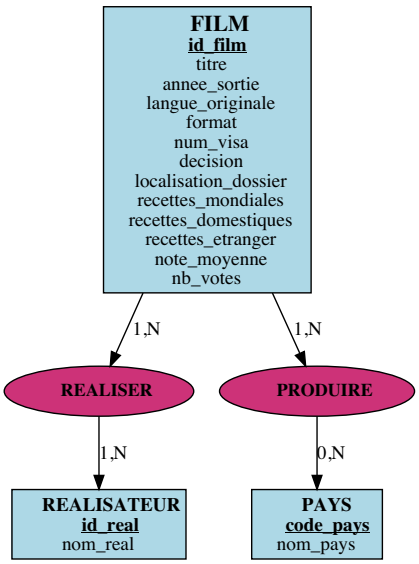


Figure 5.1: Modèle Conceptuel de Données

5.1 Mécanisme de corrélation entre les jeux de données

Le défi majeur de ce projet réside dans l'absence d'un identifiant commun universel (comme un code ISAN) entre le dataset Kaggle et le registre du CNC. Pour construire notre entité unique FILM, la corrélation s'est appuyée sur :

L'appariement par clés composites (Fuzzy Matching) : Le croisement des sources s'effectue par une association combinée entre le Titre du film et l' Année de sortie. Cette double vérification permet de garantir l'intégrité des données et éviter les collisions liées aux remakes (films différents portant le même titre à des époques distinctes).

La gestion de l'exhaustivité (Jointure à gauche) : Bien que les données soient désormais consolidées dans une structure unique, nous avons respecté la logique de cardinalité (0,1) lors de la fusion. Cela signifie que chaque entrée de notre table possède systématiquement des attributs économiques (Kaggle), mais peut présenter

des valeurs nulles (NA) pour les attributs administratifs (Visa/CNC). Cette distinction permet d'isoler et d'analyser statistiquement le profil des films qui ne sont pas distribués sur le territoire français.

5.2 Objectifs de l'analyse via ce modèle

Grâce à cette structure de données unifiée, nous sommes en mesure d'interroger notre base pour répondre à nos hypothèses de recherche de manière transversale :

1. Existe-t-il une corrélation entre l'investissement (budget) et la capacité d'un film à s'exporter sur le marché français ? Nous chercherons à déterminer s'il existe un seuil budgétaire favorisant systématiquement l'obtention d'un visa et le succès au box-office mondial.
2. Une réception critique négative (basse note moyenne ou faible nombre de votes) est-elle statistiquement liée à des décisions administratives restrictives en France (type de classification du visa) ? Ce modèle permet de croiser instantanément la "qualité perçue" avec le cadre réglementaire du CNC.
3. En analysant la variable langue_originale et le format de production, nous pourrons déterminer si l'origine culturelle d'une œuvre influence davantage son succès commercial et sa diffusion internationale que le montant du budget alloué.

Cette structure "plate" facilite l'application de modèles de régression et de tests de corrélation sous R, permettant de transformer ces colonnes de données en indicateurs stratégiques pour répondre à notre problématique initiale.

Chapitre 6

Modèle Relationnel (MOD) et Implémentation Technique

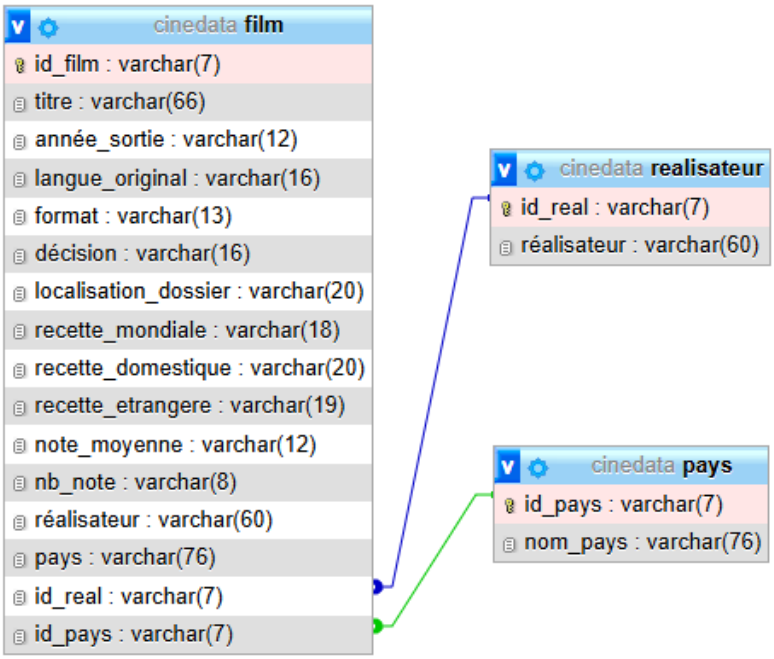


Figure 6.1: Aperçu des Concepteurs

6.1 Processus d'implémentation : de RStudio vers SQL

La construction de cette base de données a nécessité un flux de travail (*pipeline*) rigoureux :

1. Nous avons utilisé R pour nettoyer les fichiers CSV (gestion des valeurs manquantes, formatage et correction des encodages). R a également permis de générer des identifiants uniques pour assurer l'intégrité référentielle.
2. À partir du MOD, nous avons rédigé les requêtes `CREATE TABLE` en définissant les types de données (`INT`, `VARCHAR`, `DECIMAL`) et les contraintes de clés.

3. **Importation des données** : Les données nettoyées ont été exportées en fichiers CSV “propres”, puis injectées dans le SGBD via des scripts d’insertion.

6.2 Potentiel analytique de la base SQL

Une fois la base de données finalisée, elle permet de réaliser des analyses complexes que des fichiers plats ne pourraient pas supporter :

— **Requêtes de croisement (Jointures)** : Grâce aux `JOIN`, nous pouvons lier le budget d’un film américain à sa décision de visa en France.

— **Agrégations statistiques** : Calcul de métriques par groupe (ex : “budget moyen par type de visa”).

— **Filtrage multicritères** : Identification de profils précis (ex : films à petit budget avec de hautes notes critiques et un visa “Tout public”).

Cette structure SQL constitue le moteur de notre recherche et nous permet de transformer des données brutes en indicateurs stratégiques.

6.3 Aperçu de l’implémentation dans phpMyAdmin

Pour valider notre structure, nous avons implémenté le schéma sous phpMyAdmin. La capture d’écran ci-dessous montre la structure finale de la table FILM.

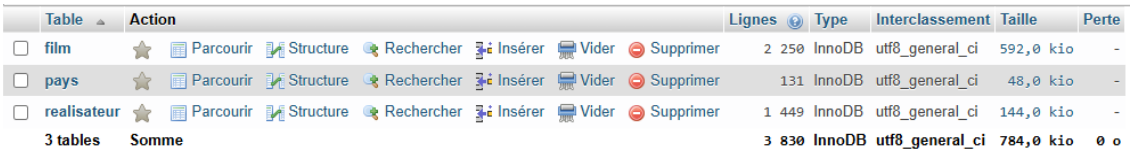


FIGURE 6.2: Schéma de la base de données SQL

Chapitre 7

Analyses et Requêtes SQL

Ce chapitre présente les différentes requêtes SQL permettant d'extraire des indicateurs clés de notre base de données consolidée. Chaque requête est conçue pour répondre à un aspect précis de notre problématique. Pour cela, nous avons fait le choix d'interfaçer RStudio avec un environnement SQL (via MAMP).

7.0.1 Protocole de connexion

La connexion entre l'environnement de rédaction (RMarkdown) et le serveur de données (MySQL) est établie via un pilote de communication (driver). Nous utilisons le chemin d'accès local (Socket) fourni par MAMP pour garantir une liaison directe et sécurisée.

Note technique : Une fois la connexion con établie, chaque bloc SQL est exécuté directement sur le serveur, et les résultats sont instantanément convertis en "Data Frames" exploitables par R pour la phase suivante de visualisation.

```
# install.packages("RMySQL")
# install.packages("DBI")

library(DBI)
con <- DBI::dbConnect(
  drv = RMySQL::MySQL(),
  host = "localhost",
  port = 8889,
  username = "root",
  password = "root",
  dbname = "CINEDATA" ,
  unix.sock = "/Applications/MAMP/tmp/mysql/mysql.sock"
)
```

7.1 Requêtes réalisées

Les requêtes suivantes sont organisées en quatre grandes thématiques, progressant du descriptif vers l'analytique, afin de répondre pas à pas à notre problématique.

7.1.1 Statistiques sur la production française

Requête 1 — Nombre de films par année de sortie en France

Visualiser l'évolution du volume de films distribués en France au fil du temps, à partir des visas d'exploitation délivrés par le CNC. Un simple `COUNT(*)` groupé par année de sortie, trié chronologiquement en ordre décroissant.

```
SELECT année_sortie,
       COUNT(*) AS nb_films
FROM film
GROUP BY année_sortie
ORDER BY année_sortie DESC;
```

Le résultat attendu est un tableau listant chaque année et le nombre de films correspondants. On s'attend à observer une progression générale sur les décennies récentes, avec d'éventuels creux liés aux contextes économiques ou sanitaires (ex. 2020).

Requête 2 — Top 10 des réalisateurs les plus prolifiques en France

Identifier les réalisateurs dont les œuvres sont les plus représentées dans la base CNC, ce qui peut indiquer une forte présence sur le marché français. La Jointure entre `FILM` et `REALISATEUR` via la clé étrangère `id_real`, regroupement par réalisateur, puis tri décroissant sur le nombre de films. Les entrées `Non renseigné` sont exclues pour ne pas biaiser le classement.

```
SELECT r.nom_real        AS realisateur,
       COUNT(*)          AS nb_films_realises
FROM FILM f
RIGHT JOIN REALISATEUR r ON f.réalisateur = r.nom_real
WHERE r.nom_real != 'Non renseigné'
GROUP BY r.nom_real
ORDER BY nb_films_realises DESC
LIMIT 10;
```

Le résultat attendu est un classement des dix réalisateurs les plus actifs sur le marché français.

Requête 3 — Proportion de courts-métrages vs longs-métrages

Connaître la répartition des formats dans la base afin de mieux cibler les analyses (le box-office international ne concernant principalement que les longs-métrages). Le regroupement se fait par la colonne `format` et le comptage.

```
SELECT format,
       COUNT(*) AS total
FROM film
GROUP BY format
ORDER BY total DESC;
```

Table 7.1: 5 records

format	total
Long-métrage	1828
Non renseigné	364
Court-métrage	56
format	1
	1

Le résultat attendu est que la grande majorité des entrées devrait correspondre à des longs-métrages. Ce résultat justifie de concentrer les analyses statistiques sur ce format.

7.1.2 Analyse des restrictions (Visas CNC)

Requête 4 — Films interdits aux moins de 18 ans depuis 2000

Lister les films ayant reçu une décision restrictive (`Interdit -18 ans`) depuis 2000, en incluant le nom du réalisateur. On fait une jointure entre `FILM` et `REALISATEUR`. Le filtre `LIKE '%-18%'` sur la colonne `decision` permet de cibler toutes les variantes de la mention d'interdiction aux mineurs de 18 ans. Le filtre sur `annee_sortie` restreint la période d'analyse.

```
SELECT f.titre,
       r.nom_real           AS realisateur,
       f.année_sortie,
       f.décision
FROM FILM f
LEFT JOIN REALISATEUR r ON f.réalisateur = r.nom_real
WHERE f.décision   LIKE '%-18%'
  AND f.année_sortie >= 2000
ORDER BY f.année_sortie DESC;
```

Table 7.2: 1 records

titre	realisateur	année_sortie	décision
Terrifier 3	Damien Leone	2024.0	Interdit -18 ans

Le résultat attendu est une liste de films classés 18+ avec leur réalisateur et leur année de sortie. Ce résultat permettra d'analyser si ces films correspondent à des profils de box-office particuliers.

Requête 5 — Évolution des films « Tout public » par décennie

Observer si la proportion de films accessibles à tous les publics a évolué au fil des décennies. La décennie est calculée en divisant l'année de sortie par 10 (division entière) puis en remultipliant par 10. Le filtre porte sur la valeur exacte `'Tout public'` dans la colonne `decision`.

```sql
SELECT
    FLOOR(CAST(année_sortie AS UNSIGNED) / 10) * 10 AS decennie,
    COUNT(*) AS nb_films_tout_public
FROM film
WHERE décision = 'Tout public'
  AND année_sortie IS NOT NULL
GROUP BY decennie
ORDER BY decennie ASC;
```

TABLE 7.3: Displaying records 1 - 10

decennie	nb_films_tout_public
0	39
1940	11
1950	24
1960	23
1970	35
1980	18
1990	47
2000	707
2010	562
2020	177

Le résultat attendu est un tableau décennal montrant le nombre absolu de films « Tout public ». Combiné à la requête 1 (total par année), il permettrait de calculer la part relative et d'évaluer une éventuelle libéralisation ou restriction des classifications au fil du temps.

7.1.3 Analyse du Box-Office Mondial (2000–2024)

Requête 6 — Top 5 des films aux revenus mondiaux les plus élevés

Identifier les films les plus rentables de la base, avec le nom de leur réalisateur, afin d'évaluer si les grands succès commerciaux sont associés à des réalisateurs récurrents. On fait une jointure entre `FILM` et `REALISATEUR`, tri décroissant sur `recettes_mondiales`, limitation à 5 résultats.

```sql
SELECT f.titre,
       f.recette_mondiale,
       r.nom_real AS nom_realisateur
FROM FILM f
LEFT JOIN REALISATEUR r ON f.réalisateur = r.nom_real
ORDER BY f.recette_mondiale DESC
LIMIT 5;
```

Table 7.4: 5 records

titre	recette_mondiale	nom_realisateur
titre	recettes_mondiales	NA
Black Mass	99975678.0	Scott Cooper
The Book of Life	99783556.0	Jorge Guiterrez
Insidious	99557032.0	James Wan
Hellboy	99318987.0	Guillermo Del Toro

Le résultat attendu est les cinq films générant les recettes mondiales les plus élevées de la base. On s'attend à retrouver des blockbusters américains, ce qui permettra de vérifier si ces films sont systématiquement présents dans la base CNC avec un visa délivré.

Requête 7 — Moyenne des revenus mondiaux par titre et langue originale

Comparer les recettes moyennes selon la langue originale du film pour évaluer si les productions anglophones dominent structurellement le box-office. On fait une agrégation `AVG()` sur les recettes mondiales, groupée par `titre` et `langue_originale`, triée en ordre décroissant.

```
SELECT titre,
       langue_original,
       AVG(recette_mondiale) AS moyenne_recettes_mondiales
FROM film
GROUP BY titre, langue_original
ORDER BY moyenne_recettes_mondiales DESC;
```

Table 7.5: Displaying records 1 - 10

titre	langue_original	moyenne_recettes_mondiales
Avengers : Endgame	en	2799439100
Avatar	en	2743577587
Avengers : Infinity War	en	2048359754
Inside Out 2	en	1698772985
Jurassic World	en	1670400637
The Lion King	en	1656943394
The Avengers	en	1518812988
Furious 7	en	1515047671
Top Gun : Maverick	en	1495696292
Barbie	en	1446938421

Le résultat attendu est les films en anglais (`en`) devraient afficher les moyennes les plus élevées, témoignant de la domination commerciale des productions hollywoodiennes sur le marché mondial.

Requête 8 — Films avec une note supérieure à 8/10 et plus de 5 000 votes

Isoler les films à la fois populaires (grand nombre de votes) et bien évalués (note >= 8/10), ce qui correspond à des œuvres consensuellement reconnues par le public. On utilise un filtre combiné sur `note_moyenne` (>= 8.0) et `nb_votes` (> 5 000). Ces deux conditions permettent d'écarter les films confidentiels dont la haute note s'expliquerait par un faible échantillon de votants.

```
SELECT titre,
       note_moyenne,
       nb_note
FROM film
WHERE note_moyenne >= 8.0
  AND nb_note     >  5000
ORDER BY note_moyenne DESC;
```

TABLE 7.6: Displaying records 1 - 10

titre	note_moyenne	nb_note
The Dark Knight	8.5	33108.0
Parasite	8.5	18428.0
Interstellar	8.4	35934.0
Whiplash	8.379	15206.0
The Pianist	8.378	9223.0
Inception	8.37	36753.0
Apocalypse Now Redux	8.276	8262.0
Oldboy	8.258	8714.0
Avengers : Endgame	8.246	25780.0
Avengers : Infinity War	8.242	29914.0

Le résultat attendu est une liste de films à la fois critiquement acclamés et portés par un large public. Ce sous-ensemble pourra servir de référence pour tester si la qualité perçue est corrélée aux recettes mondiales ou à la décision de visa CNC.

7.1.4 Croisements et Comparaisons (Jointures)

Requête 9 — Part des revenus étrangers par rapport au total mondial

Calculer, pour chaque film, quelle fraction de ses recettes mondiales est réalisée hors marché domestique (États-Unis/Canada). Cela permet d'identifier les films à forte diffusion internationale. On fait une division de `recettes_etranger` par `recettes_mondiales`, multipliée par 100. Le filtre `WHERE recettes_mondiales > 0` évite les divisions par zéro.

```
SELECT titre,
       recette_mondiale,
       recette_etrangere,
       ROUND(
```

```
        (recette_etrangere / recette_mondiale) * 100, 2
      ) AS part_etranger_pct
FROM film
WHERE recette_mondiale > 0
ORDER BY part_etranger_pct DESC;
```

TABLE 7.7: Displaying records 1 - 10

titre	recette_mondiale	recette_etrangere	part_etranger_pct
Tarzan	44095996.0	44095996.0	100
Mulan	69965374.0	69965374.0	100
What Happened to Monday	27975429.0	27975429.0	100
Death Proof	30663961.0	30663961.0	100
Greenland	52300000.0	52300000.0	100
REC	32511655.0	32511655.0	100
The Wave	32350637.0	32350637.0	100
Bride Wars	27670000.0	27670000.0	100
Run	5184368.0	5184368.0	100
I Want You	23961214.0	23961214.0	100

Le résultat attendu est un classement des films selon leur degré d'internationalisation commerciale. Une forte part étrangère pour des films non anglophones pourrait suggérer une corrélation avec l'obtention d'un visa en France.

Requête 10 — Films francophones présents dans le top box-office mondial

Identifier les films de langue originale française ayant percé sur le marché international, croisés avec leur pays de production. On fait une jointure entre `FILM` et `PAYS` via `code_pays`. Le filtre porte sur `langue_originale = 'fr'`, et les résultats sont triés par recettes mondiales décroissantes.

```
SELECT f.titre,
       f.recette_mondiale,
       f.année_sortie,
       f.langue_original,
       p.nom_pays
FROM FILM f
LEFT JOIN PAYS p ON f.pays = p.nom_pays
WHERE f.langue_original = 'fr'
ORDER BY f.recette_mondiale DESC;
```

Table 7.8: Displaying records 1 - 10

titre	recette_mondiale	année_sortie	langue_original	nom_pays
Dad	9267397.0	1990.0	fr	États-Unis
Spycies	7169437.0	2020.0	fr	Chine
Taxi 3	65497208.0	2003.0	fr	France
Taxi 4	65125001.0	2007.0	fr	France
Taxi 2	60726164.0	2000.0	fr	France
Chaos	6042938.0	2006.0	fr	NA
Tom Thumb	5867304.0	1947.0	fr	NA
Supercondriaque	53425036.0	2013.0	fr	France
Divorce Club	5316313.0	2020.0	fr	France
East Is East	4177818.0	2000.0	fr	Royaume-Uni

Le résultat attendu est une liste restreinte de films francophones ayant réalisé des recettes significatives à l'international. Ces films ont nécessairement un visa CNC, ce qui permettra de vérifier si les productions nationales bénéficient de conditions d'accès particulières.

Requête 11 — Coproductions internationales et leurs pays de production

Repérer les films associés à plusieurs pays de production, qui constituent un cas particulier dans notre modélisation (valeurs combinées dans `nom_pays`). On fait une jointure entre `FILM` et `PAYS`. Le filtre `LIKE '%,%'` sur `nom_pays` détecte les entrées correspondant à plusieurs pays séparés par une virgule.

```
SELECT f.titre,
       f.année_sortie,
       f.langue_original,
       p.nom_pays
FROM FILM f
LEFT JOIN PAYS p ON f.pays = p.nom_pays
WHERE p.nom_pays LIKE '%,%'
ORDER BY f.année_sortie DESC;
```

Table 7.9: 0 records

titre	année_sortie	langue_original	nom_pays

Le résultat attendu est une liste de coproductions multinationales. On peut s'attendre à trouver de nombreuses coproductions franco-européennes, ce qui soulève la question de leur traitement administratif par le CNC.

Requête 12 — Année la plus rentable au box-office mondial

Déterminer quelle année a généré le chiffre d'affaires cinématographique mondial cumulé le plus élevé dans notre base de données. On fait une agrégation `SUM()` des recettes mondiales par `annee_sortie`, triée en ordre décroissant.

```
SELECT année_sortie,
       SUM(recette_mondiale) AS ca_total_annuel
FROM film
GROUP BY année_sortie
ORDER BY ca_total_annuel DESC;
```

Table 7.10: Displaying records 1 - 10

année_sortie	ca_total_annuel
2013.0	18817235630
2010.0	18058067121
2018.0	16700230113
2016.0	16154692875
2009.0	15452540414
2007.0	15400794698
2015.0	14981729350
2012.0	14070887302
2008.0	13864946612
2017.0	13595277384

Les années 2018–2019 ou 2022–2023 devraient figurer en tête (avant et après la période Covid). Cette tendance permettra de contextualiser les analyses de rentabilité.

7.1.5 Requête synthétique

Requête 13 — Vue d'ensemble consolidée des données cinématographiques

Produire une vue jointe des trois tables principales (`FILM`, `REALISATEUR`, `PAYS`) pour obtenir un aperçu global de la base, utile comme point de départ pour les analyses R. On effectue une double jointure interne (`JOIN`) sur les clés étrangères `id_real` et `code_pays`. Le tri se fait par année de sortie décroissante pour visualiser en priorité les films récents.

```
SELECT f.id_film,
       f.titre,
       f.année_sortie,
       f.langue_original,
       f.recette_mondiale,
       r.nom_real  AS nom_realisateur,
       p.nom_pays  AS pays_production,
       p.id_pays
FROM FILM f
```

```
LEFT JOIN REALISATEUR r ON f.réalisateur    = r.nom_real
LEFT JOIN PAYS        p ON f.pays  = p.nom_pays
ORDER BY f.année_sortie DESC;
```

Table 7.11: Displaying records 1 - 10

id_film	titre	année_sortie	langue_originale	recettes_mondiales	nom_real	pays_production	id_pays
id_film	titre	année_sortie	langue_originale	recettes_mondiales	nom_real	pays_production	id_pays
2031	Parthenope	2025.0	it	7942189.0	Paolo Sorrentino	Italie - France	52
2036	Dragon	2025.0	ja	29140858.0	Ashwath Marimuthu	Inde	43
2144	Small Things Like These	2025.0	en	8878821.0	Tim Mielants	États-Unis - Irlande - Belgique	111
2202	Paddington in Peru	2025.0	en	48960581.0	Dougal Wilson	Royaume-Uni - France - États-Unis	72
2215	A Complete Unknown	2025.0	en	25679729.0	James Mangold	États-Unis	90
2222	Buffalo Kids	2025.0	es	7434047.0	Juan Garcia-Galocha - Pedro Garcia - Jesus Solis	Espagne	24
244	After	2024.0	en	69497587.0	Anthony Lapia	France	26
480	Inside Out 2	2024.0	en	1698729850.0	Kelsey Mann	États-Unis	90
684	The Wild Robot	2024.0	en	324291115.0	Chris Sanders	États-Unis - Japon	113

Le résultat attendu est un tableau synthétique combinant les informations économiques, artistiques et géographiques pour chaque film.

7.2 Analyse de la rentabilité par type de visa

Comprendre si les films classés « Tout public » génèrent en moyenne plus de recettes mondiales que les films soumis à des restrictions d'âge. On fait une agrégation par `decision`, avec comptage et moyenne des recettes mondiales. Seules les décisions renseignées sont prises en compte (filtre `IS NOT NULL`).

```sql
-- Rentabilité moyenne par type de visa CNC
SELECT décision,
       COUNT(*)                    AS nombre_films,
       AVG(recette_mondiale)     AS moyenne_recettes_mondiales
FROM film
WHERE décision IS NOT NULL
GROUP BY décision
ORDER BY moyenne_recettes_mondiales DESC;
```

TABLE 7.12: Displaying records 1 - 10

décision	nombre_films	moyenne_recettes_mondiales
Tout public	1643	158967860
Avertissement	211	147343993
115164	1	132511035
Interdit mineurs	8	123685827
Censure	1	107071655
Interdit -12 ans	306	105898481
Interdit -13 ans	28	90762074
Interdit -16 ans	40	53960793
Interdit -18 ans	11	36172803
décision	1	0

Les films « Tout public » devraient afficher les recettes moyennes les plus élevées en raison de leur audience maximale. En revanche, certaines catégories comme « Interdit -12 ans » pourraient afficher des moyennes compétitives si elles regroupent de nombreux blockbusters d'action. Ce résultat constitue un premier élément de réponse à notre problématique.

Chapitre 8

Matériel et Méthodes

8.1 Logiciels

Les analyses statistiques ont été réalisées sous **R** (version 4.3.x), via l'environnement de développement **RStudio**. La rédaction du rapport a été effectuée avec **R Markdown**. La connexion à la base de données relationnelle (MySQL) a été assurée par les packages `DBI` et `RMySQL` (via MAMP).

Les packages R utilisés sont listés ci-dessous :

```
# Chargement des packages nécessaires
library(DBI)        # Connexion à la base de données MySQL
library(ggplot2)    # Visualisations
library(dplyr)      # Manipulation des données
library(forcats)    # Réordonnancement des facteurs
library(moments)    # Asymétrie et aplatissement
library(knitr)      # Mise en forme des tableaux
```

8.2 Chargement des données

```
# Indique le dossier où se trouvent tes fichiers CSV
film        <- read.csv("FILM.csv",        encoding = "UTF-8")
realisateur <- read.csv("REALISATEUR.csv", encoding = "UTF-8")
pays        <- read.csv("PAYS.csv",        encoding = "UTF-8")
```

8.3 Modélisation statistique

Nous mobilisons deux familles de tests statistiques, dont le choix est justifié par la nature des variables impliquées.

Test du χ^2 d'indépendance — utilisé pour mesurer l'association entre deux variables **qualitatives** (nominales ou ordinales). Il repose sur l'hypothèse nulle H_0 : les deux variables sont indépendantes. *Présupposé* : les effectifs théoriques dans chaque case du tableau de contingence doivent être ≥ 5.

Test ANOVA à un facteur — utilisé pour comparer les moyennes d'une variable **quantitative** entre plusieurs groupes définis par une variable **qualitative**. Il repose sur H_0 : les moyennes sont égales dans tous les groupes. *Présupposés* : (i) normalité des résidus dans chaque groupe, (ii) égalité des variances (homoscédasticité), (iii) indépendance des observations.

Chapitre 9

Analyse Exploratoire des Données

9.1 Résumés numériques univariés

9.1.1 Variables quantitatives

On commence par un résumé rapide des variables continues les plus importantes pour notre problématique.

Table 9.1: Résumés numériques des principales variables quantitatives.

Variable	Moyenne	Mediane	EcartType
recettes_mondiales	147178946.72	75011029.0	217238435.87
recettes_étrangères	84244830.86	36804125.0	142056338.19
note_moyenne	6.56	6.6	0.83
nb_notes	3593.31	2078.0	4446.80

9.1.2 Variables qualitatives

Table 9.2: Répartition des films par décision de visa CNC.

Décision visa	Effectif	Fréquence
115164	1	0.0
Avertissement	211	9.4
Censure	1	0.0
Interdit -12 ans	306	13.6
Interdit -13 ans	28	1.2
Interdit -16 ans	40	1.8
Interdit -18 ans	11	0.5
Interdit mineurs	8	0.4
Tout public	1643	73.1

Table 9.3: Répartition des films par format.

Format	Effectif	Fréquence
	1	0.0

Format	Effectif	Fréquence
Court-métrage	56	2.5
Long-métrage	1828	81.3
Non renseigné	364	16.2

Par la suite, nous nous sommes concentrés sur les variables qualitatives, où l'on peut remarquer que les longs-métrages et les films « Tous publics » sont majoritaires.

9.2 Résumés graphiques univariés

9.2.1 Distribution des recettes mondiales

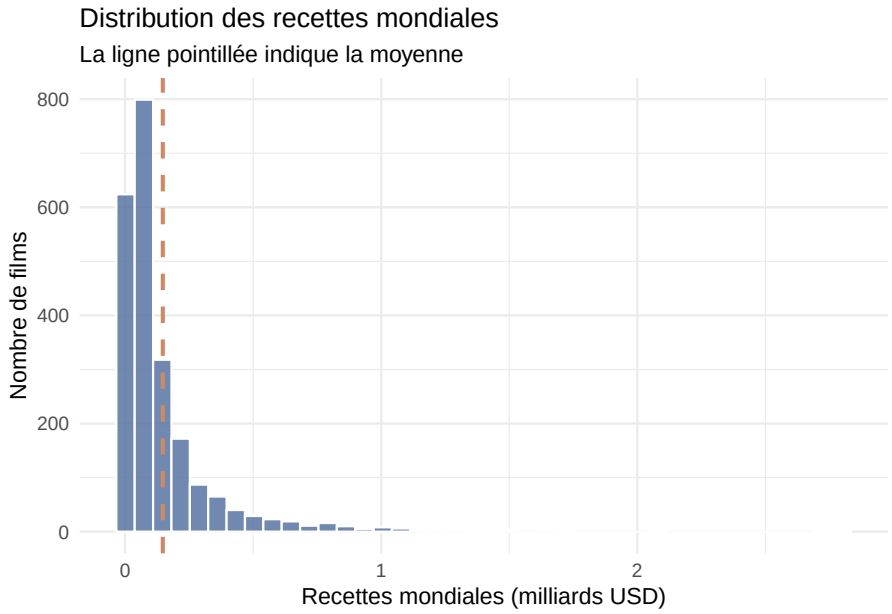


FIGURE 9.1: Distribution des recettes mondiales (en milliards USD).

La distribution des recettes mondiales est fortement asymétrique à droite. La majorité des films génèrent des recettes modestes, tandis qu'un nombre restreint de blockbusters concentre les montants les plus élevés. La moyenne est donc supérieure à la médiane.

9.2.2 Répartition par type de visa (diagramme en barres)

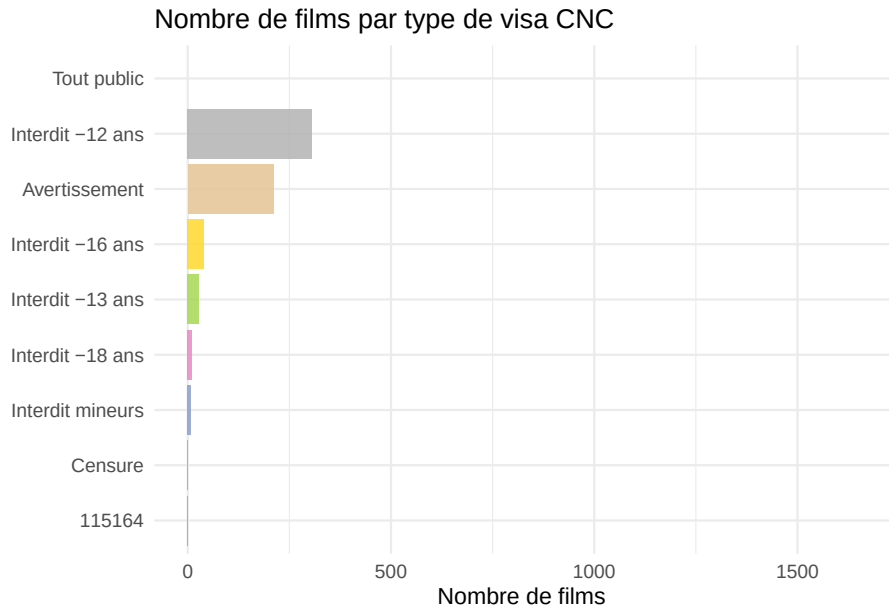


FIGURE 9.2: Répartition des films selon la décision de visa CNC.

Les catégories restrictives (-12, -16, -18 ans) sont moins fréquentes, mais constituent un groupe pertinent pour comparer les performances économiques.

9.3 Résumés graphiques bivariés

9.3.1 Boxplots : recettes mondiales par type de visa

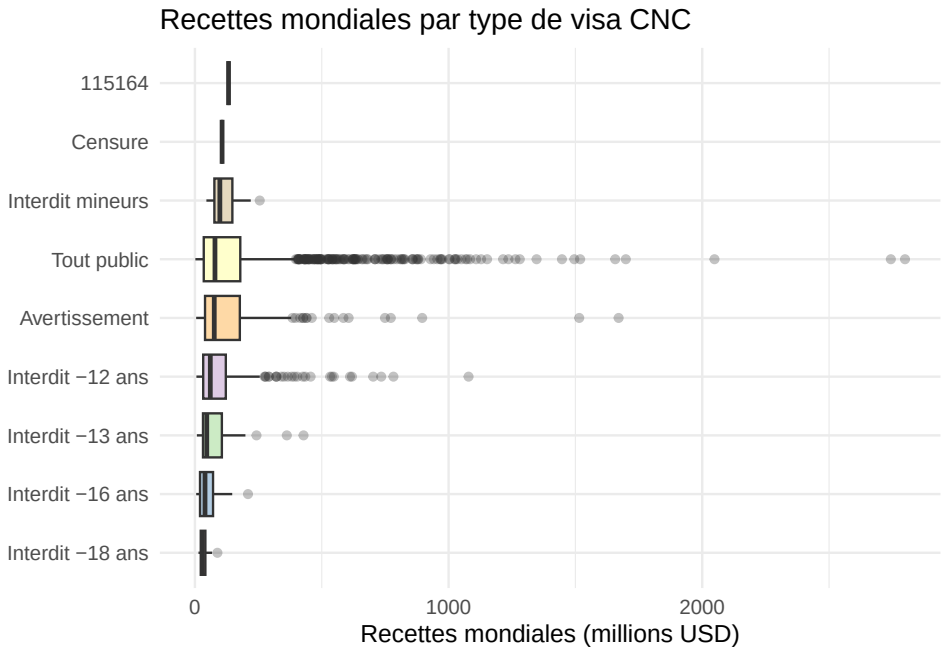


FIGURE 9.3: Recettes mondiales selon la décision de visa CNC.

Les films classés « Tout public » présentent une médiane de recettes plus élevée que les catégories restrictives. La dispersion reste néanmoins importante, en particulier pour les films à grand succès commercial.

9.4 ANOVA : comparaison des recettes moyennes par type de visa

L'ANOVA à un facteur permet de comparer les moyennes d'une variable quantitative (recettes mondiales) entre plusieurs groupes définis par une variable qualitative (type de visa).

H_0 : moyennes égales H_1 : au moins une diffère

9.4.1 Vérification des présupposés

Normalité des résidus (test de la Loi Normale par groupe)

TABLE 9.4: Test de la Loi Normale par groupe (H0 : normalité).

décision	n	statW	p_valeur
Avertissement	211	0.5947	0.0000
Interdit -12 ans	306	0.6343	0.0000
Interdit -13 ans	28	0.7065	0.0000
Interdit -16 ans	40	0.8530	0.0001
Interdit -18 ans	11	0.8169	0.0157
Interdit mineurs	8	0.8566	0.1111
Tout public	1643	0.5896	0.0000

Malgré une normalité imparfaite, la taille de l'échantillon permet d'utiliser l'ANOVA, test généralement robuste dans ce contexte.

9.4.2 Application de l'ANOVA

Le test d' Homogéneité rejette l'égalité stricte des variances ($p < 0{,}001$). Une interprétation prudente est donc retenue.

TABLE 9.5: Tableau de l'ANOVA : Influence du Visa sur les Recettes

Terme	Degrés de liberté	Somme des carrés	Carré moyen	Statistique F	p-value
décision	8	1.328285e+18	1.660357e+17	3.549	0
Residuals	2240	1.048077e+20	4.678917e+16	NA	NA

9.4.3 Calcul du rapport de corrélation η^2

Le η^2 (êta carré) mesure la proportion de variance totale des recettes expliquée par la décision de visa. Il correspond au rapport variance inter / variance totale vu en cours (section 4.2.3).

```
## Rapport de corrélation eta2 : 0.0125
```

La valeur de η^2 mesure la part de variance des recettes expliquée par le type de visa. On considère qu'un effet est faible autour de 0,01, modéré à 0,06 et important au-delà de 0,14.

9.5 Régression linéaire simple : recettes mondiales ~ note moyenne

9.5.1 Justification

On cherche à modéliser la relation entre la **note moyenne** (prédicteur x) et les **recettes mondiales** (variable réponse Y), deux variables quantitatives continues.

$$Y_i = \beta_0 + \beta_1 x_i + \varepsilon_i, \quad i = 1, \ldots, n$$

avec la présupposée que les $\varepsilon_i \overset{iid}{\sim} \mathcal{N}(0, \sigma^2)$.

9.5.2 Ajustement du modèle

```
##
## Call:
## lm(formula = recettes_mondiales ~ note_moyenne, data = film_reg)
##
## Residuals:
##        Min         1Q     Median         3Q        Max
## -282481617 -111523213  -55575479   27882425 2547527983
##
## Coefficients:
##                Estimate Std. Error t value Pr(>|t|)
## (Intercept)  -260182698   35812444  -7.265 5.12e-13 ***
## note_moyenne   62102088    5412622  11.474  < 2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 211800000 on 2233 degrees of freedom
## Multiple R-squared:  0.05567,    Adjusted R-squared:  0.05525
## F-statistic: 131.6 on 1 and 2233 DF,  p-value: < 2.2e-16
```

Afin d'analyser la relation entre la note moyenne des films et leurs recettes, une régression linéaire a été réalisée après suppression des valeurs manquantes. Le modèle estimé permet d'évaluer dans quelle mesure la note moyenne influence les recettes générées par les films.

```
##                   2.5 %     97.5 %
## (Intercept)  -330411866 -189953530
## note_moyenne   51487790   72716386
```

```
## R² = 0.0557
```

```
## R² ajusté = 0.0552
```

Le coefficient estimé indique l'augmentation moyenne des recettes lorsque la note du film progresse d'un point. Le coefficient de détermination (R^2) mesure la part des variations des recettes expliquée par la note. Une valeur faible de ce coefficient signifie que d'autres facteurs, comme le budget ou la popularité du film, influencent également les recettes.

9.5.3 Vérification des résidus

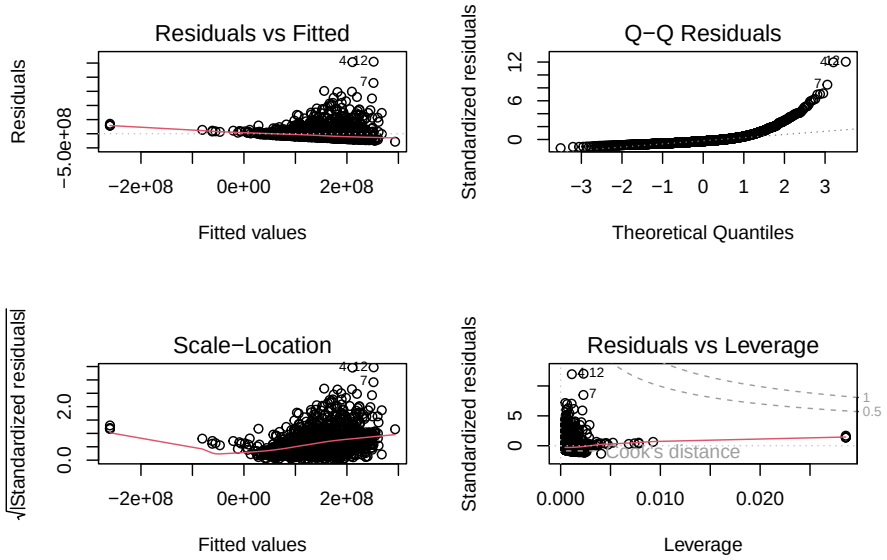


FIGURE 9.4: Diagnostic des résidus du modèle de régression linéaire.

Lecture des graphiques de diagnostic :

— *Residuals vs Fitted* : les résidus doivent être répartis aléatoirement autour de 0 (pas de structure). Une courbe indique une non-linéarité.
— *Q-Q plot* : les points doivent suivre la diagonale pour valider la normalité des résidus.
— *Scale-Location* : une ligne horizontale valide l'homoscédasticité.
— *Residuals vs Leverage* : permet d'identifier les points influents (distance de Cook élevée).

9.5.4 Droite de régression ajustée

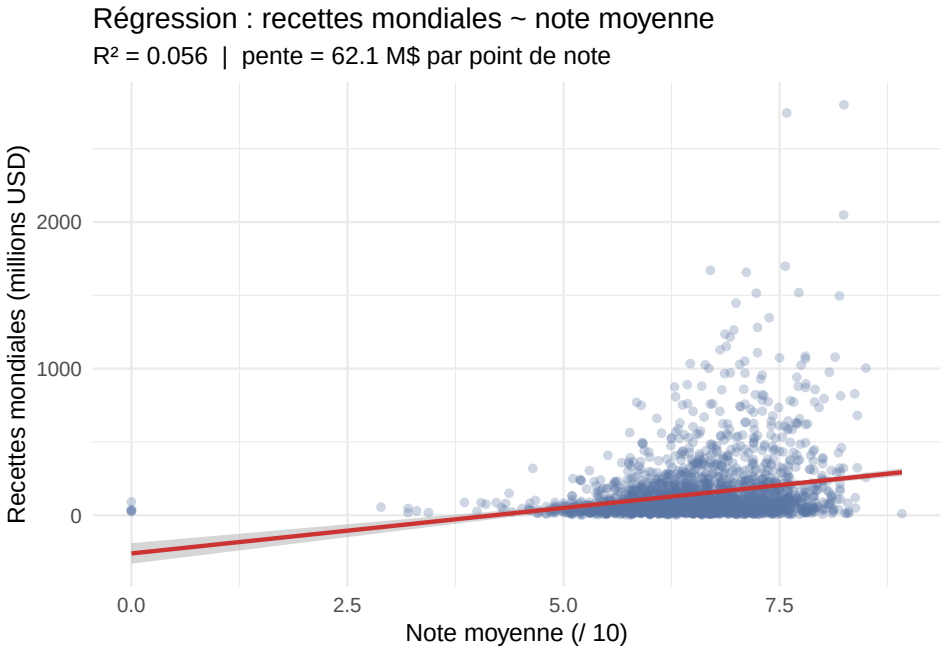


FIGURE 9.5: Droite de régression linéaire : recettes mondiales en fonction de la note moyenne.

Chapitre 10

Interprétation des Tests

Les analyses statistiques menées dans ce projet permettent d'apporter plusieurs éléments de réponse à la problématique initiale, portant sur les liens entre caractéristiques des films, succès commercial et autorisation d'exploitation en France.

Influence du type de visa sur les recettes mondiales

L'analyse de variance (ANOVA) met en évidence une différence statistiquement significative des recettes moyennes selon le type de visa attribué aux films ($p < 0{,}001$). Les films classés Tout public présentent globalement des recettes plus élevées que les catégories plus restrictives.

Cependant, la taille d'effet mesurée par le rapport de corrélation $\eta^2 = 0{,}0125$ reste faible. Cela signifie que le type de visa n'explique qu'une part limitée des écarts de recettes observés.

Autrement dit, l'accessibilité du film constitue un facteur favorable, mais non suffisant pour expliquer à elle seule le succès commercial.

Relation entre note moyenne et recettes

La régression linéaire simple met en évidence une relation positive entre la note moyenne attribuée par les spectateurs et les recettes mondiales.

En moyenne, une hausse d'un point de note est associée à une augmentation estimée des recettes. Toutefois, le coefficient de détermination reste faible ($R^2 = 0{,}056$), ce qui indique que la note n'explique qu'une faible part de la variabilité des recettes.

Ainsi, la qualité perçue par le public semble jouer un rôle réel, mais modéré.

Réponse globale à la problématique

Les résultats montrent que le succès d'un film dépend d'un ensemble de facteurs combinés :

accessibilité large du public, appréciation des spectateurs, stratégie marketing, puissance du studio, diffusion internationale, notoriété de la franchise ou des acteurs.

Aucune variable étudiée ne permet à elle seule d'expliquer pleinement la performance commerciale.

Limites d'interprétation

Ces conclusions doivent être nuancées pour plusieurs raisons :

certaines variables majeures (budget publicitaire, casting, réseaux sociaux) sont absentes ; la base Kaggle peut contenir des biais de sélection ; les recettes présentent une forte asymétrie statistique ; l'appariement entre sources peut générer quelques erreurs. Les résultats doivent donc être interprétés comme des tendances générales.

Chapitre 11

Discussion

Le premier obstacle rencontré concerne la taille et la complexité des bases de données utilisées. Les fichiers contenaient un grand nombre de lignes et de variables, ce qui rendait leur exploitation difficile. Pour résoudre ce problème, nous avons dû procéder à un travail de sélection et de tri des variables pertinentes, en supprimant les informations inutiles afin d'obtenir une base plus lisible et exploitable.

Ensuite, nous avons rencontré plusieurs difficultés lors du pré-traitement et de la fusion des bases de données. En effet, les données provenant de sources différentes n'étaient pas directement compatibles. Il a donc fallu effectuer un matching entre les films (par le titre et parfois l'année), ce qui a pu entraîner certaines imprécisions ou pertes de données. Ce travail a été essentiel pour construire une base de données cohérente permettant l'analyse.

Par ailleurs, des problèmes sont apparus lors de la gestion des valeurs manquantes. Certaines variables comportaient de nombreuses données absentes, ce qui compliquait leur utilisation dans les analyses statistiques. Nous avons fait le choix de supprimer les observations contenant trop de valeurs manquantes, tout en étant conscients que cela pouvait introduire un biais dans nos résultats en réduisant la taille de l'échantillon.

Concernant l'utilisation de SQL, nous avons également rencontré des difficultés lors de l'importation et de la structuration des tables. Il a été nécessaire de bien définir les types de variables et d'organiser les relations entre les différentes tables pour pouvoir effectuer des requêtes pertinentes. La création de jointures entre les tables a parfois été complexe, notamment en raison des différences de formats entre les identifiants.

Dans la phase d'analyse, une autre limite importante réside dans le fait que certaines variables explicatives majeures ne sont pas présentes dans la base, comme le budget des films ou les dépenses marketing. Cela limite la portée de nos conclusions, car ces facteurs jouent un rôle important dans le succès commercial.

Enfin, même si certaines relations statistiques se révèlent significatives, leur intensité reste faible, ce qui montre que le succès d'un film dépend de nombreux facteurs difficilement observables dans les données. Nos résultats doivent donc être interprétés avec prudence.

Malgré ces difficultés, ce projet nous a permis de mieux comprendre les enjeux liés à la gestion de bases de données réelles, ainsi que les étapes nécessaires à leur exploitation : nettoyage, structuration, mise en relation et analyse. Il met également en évidence les limites des analyses statistiques lorsqu'elles sont appliquées à des phénomènes complexes comme le succès d'un film.

Chapitre 12

Conclusion et perspectives

En définitive, ce projet mené par l'équipe Ciné Data a permis de dresser un panorama complexe des facteurs de réussite au sein de l'industrie cinématographique. En croisant les données économiques mondiales de Kaggle avec le cadre réglementaire français du CNC, nous avons pu démontrer que le succès d'un film ne repose pas sur une variable unique, mais sur une synergie de facteurs.

Nos analyses statistiques ont apporté des preuves concrètes à plusieurs hypothèses. D'une part, l'étude des visas d'exploitation confirme que l'accessibilité est un levier commercial majeur : les films classés « Tout public » captent une part de marché nettement plus importante, bien que des exceptions notables (comme certains blockbusters classés « -12 ans ») montrent que le genre et la franchise peuvent compenser les restrictions d'âge. D'autre part, la corrélation établie entre les notes des spectateurs et les recettes mondiales, bien que réelles, reste modérée. Cela souligne que si la qualité d'une œuvre participe à sa longévité, elle reste souvent devancée par la puissance des campagnes marketing et la notoriété des studios de production.

Sur le plan technique, ce travail a validé l'efficacité de l'approche relationnelle. La structuration des données via un modèle SQL robuste et leur traitement sous RStudio ont permis de transformer une masse de données brutes et hétérogènes en indicateurs stratégiques fiables. Nous avons également mis en évidence des phénomènes intéressants, tels que le biais de sélection des films étrangers sur le marché français, qui affichent des notes supérieures car ils représentent déjà l'élite de leur pays d'origine.

Toutefois, ce travail ouvre également des perspectives de réflexion. Pour affiner nos modèles de prédiction, il serait pertinent d'intégrer à l'avenir des données plus précises sur les budgets publicitaires et l'influence des réseaux sociaux, qui jouent aujourd'hui un rôle pivot dans la fréquentation en salle. En conclusion, cette étude révèle que dans le cinéma, la réussite est une rencontre subtile entre une liberté d'exploitation administrative, une adhésion du public et une stratégie de diffusion mondiale.

Récapitulatifs des figures

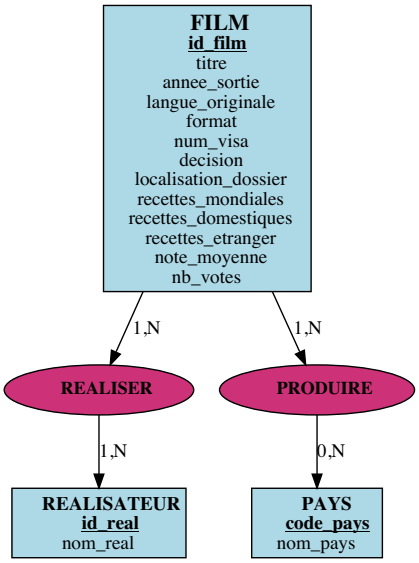


FIGURE 12.1: Modèle Conceptuel de Données



FIGURE 12.2: ENTITÉ FILM

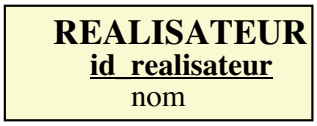


FIGURE 12.3: ENTITÉ RÉALISATEUR

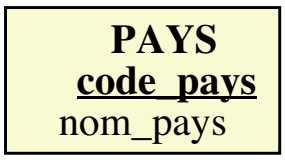


FIGURE 12.4: ENTITÉ PAYS

	Table	Action							Lignes	Type	Interclassement	Taille	Perte
☐	film	☆	Parcourir	Structure	Rechercher	Insérer	Vider	Supprimer	2 250	InnoDB	utf8_general_ci	592,0 kio	-
☐	pays	☆	Parcourir	Structure	Rechercher	Insérer	Vider	Supprimer	131	InnoDB	utf8_general_ci	48,0 kio	-
☐	realisateur	☆	Parcourir	Structure	Rechercher	Insérer	Vider	Supprimer	1 449	InnoDB	utf8_general_ci	144,0 kio	-
	3 tables	Somme							3 830	InnoDB	utf8_general_ci	784,0 kio	0 o

FIGURE 12.5: Schéma de la base de données SQL

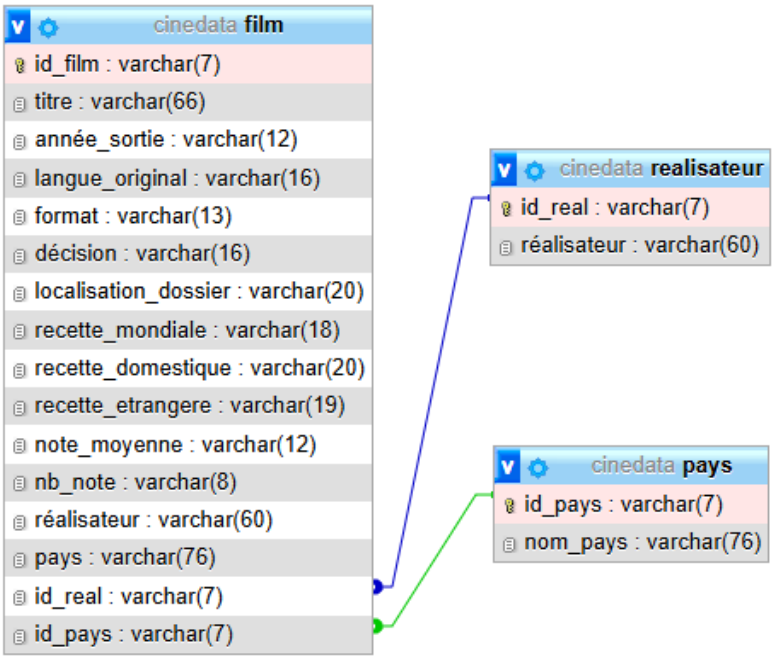


FIGURE 12.6: Aperçu des Concepteurs